영상 해상도 및 프레임률 저하에 따른 rPPG 심박수 추정 성능의 붕괴 지점 분석

고은비[1], 정종진[2], 김승현[2*]
[1]대진대학교 일반대학원 방산AI융합학과, [2]대진대학교 AI융합대학 교수

Breakdown Point Analysis of rPPG-Based Heart Rate Estimation Performance Under Degraded Video Resolution and Frame Rate

Eunbi Ko[1], Jongjin Jeong[2], and Seunghyeon Kim[2*]
[1]Department of Defense AI Convergence, Graduate School, Daejin University
[2]Professors, College of AI Convergence, Daejin University

Abstract - 원격 광용적맥파(rPPG)는 얼굴 영상으로 심박수를 비접촉 추정하는 기술이나, 실제 환경의 영상은 프레임률과 해상도가 낮은 경우가 많아 어느 조건까지 성능이 유지되는지는 충분히 비교되고 있지 않다. 본 연구는 입력 영상의 프레임률(30~5fps)과 해상도(640×480~40×30)를 단계적으로 낮추며, 알고리즘 기반의 대표적 추출 기술 3종(GREEN, POS, CHROM) 뿐 아니라 사전학습 딥러닝 기반의 신호 추정 기술 3종(PhysNet, PhysFormer, PhysMamba)의 심박수 추정 성능이 무너지는 지점을 UBFC-rPPG, PURE, MMPD 총 3가지의 데이터셋에 대해 비교를 진행하였다. 딥러닝은 학습 데이터와 겹치지 않도록 PURE로 학습된 가중치로 평가하였다. 실험 결과 알고리즘은 15fps까지 원본 수준을 유지하였고 5fps(CHROM은 10fps)에서는 구조적으로 평가할 수 없었다. 딥러닝은 UBFC에서 15fps부터 성능이 크게 저하되었으나 PURE에서는 10fps까지 유지되어 붕괴 지점이 데이터셋에 따라 달랐고, SNR은 MAE보다 먼저 감소하였다. 해상도는 160×120까지 영향이 거의 없었고 80×60 이하에서 성능이 급락하였으나 이 구간에서는 얼굴 검출 실패가 함께 발생하여 해상도 자체의 영향과 분리할 수 없었다. 본 결과는 저해상도, 저프레임률 환경에서 rPPG 방법을 적용할 수 있는 조건을 판단하는 기초 자료를 제시한다.

1. 서 론

원격 광용적맥파(remote photoplethysmography, rPPG)는 얼굴 영상에 나타나는 미세한 피부색 변화로부터 심박수를 비접촉으로 추정하는 기술이다. Verkruysse 등[1]은 일반 디지털 카메라와 주변광만으로 얼굴 영상에서 맥파 신호를 얻을 수 있음을 보였다. 이후 색 신호를 수식으로 처리해 맥파를 추출하는 알고리즘 기반 방법들이 제안되었다. 대표적으로 녹색 채널을 사용하는 GREEN[1], 색차 신호를 이용해 움직임의 영향을 줄인 CHROM[2], 피부 반사 모델에 기반해 피부색에 직교하는 평면으로 신호를 투영하는 POS[3]이 있다.

최근에는 신경망 학습으로 신호를 추정하는 딥러닝 기반 방법이 활발히 연구되고 있다. PhysNet[4]는 3차원 합성곱 신경망으로 얼굴 영상의 시공간 특징을 학습하여 맥파 신호를 직접 출력한다. PhysFormer[5]는 시간 차분 기반의 트랜스포머 구조로 장거리 시간 관계를 학습한다. PhysMamba[6]은 Mamba 구조를 도입해 긴 시계열을 효율적으로 처리한다. 또한 rPPG-Toolbox[7]이 공개되면서 여러 방법을 같은 전처리와 평가 조건에서 비교할 수 있게 되었다.

그러나 이러한 방법들은 대부분 공개 데이터셋이 제공하는 원본 프레임률과 해상도 한 가지 조건에서만 평가되었다. 실제 환경에서는 저사양 카메라, 저전력 모드, 온디바이스 및 엣지 디바이스 처리 등의 이유로 영상의 프레임률과 해상도가 낮은 경우가 많다. 영상 품질 저하의 영향을 다룬 연구로, Blackford와 Estepp[8]은 프레임률과 해상도를 낮추며 맥박수 측정 정확도를 분석하였고, McDuff 등[9]는 영상 압축이 심박 신호 측정에 미치는 영향을 분석하였다. 하지만 이 연구들은 딥러닝 기반 방법이 본격적으로 등장하기 전에 수행되어 알고리즘 기반 방법만을 다루었다. 따라서 같은 품질 저하에 알고리즘 기반 방법과 딥러닝 기반 방법이 어떻게 다르게 반응하는지, 그리고 어느 수준까지 사용할 수 있는지는 충분히 비교되지 않았다.

이를 확인하기 위해 본 연구는 입력 영상의 프레임률과 해상도를 단계적으로 낮추며 심박수 추정 성능을 평가하였다. 알고리즘 기반 방법 3종(GREEN, POS, CHROM)과 사전학습된 딥러닝 모델 3종(PhysNet, PhysFormer, PhysMamba)을 공개 데이터셋 3종(UBFC-rPPG[10], PURE[11], MMPD[12])에서 같은 평가 지표로 비교하였다.

2. 본 론

2.1 실험 설계

2.1.1 데이터 설정

UBFC-rPPG는 42개 중 15개는 파일 헤더가 선언한 크기보다 실제 크기가 작아서 정답 길이와 맞지 않아 제외하였다. PURE는 딥러닝 시 사전학습 가중치의 학습 구간과 겹치지 않게 세션의 뒤 20%만 사용하였다. 손상된 PNG 15개는 같은 세션의 이웃 프레임으로 대체하였다. MMPD는 제공하는 모든 데이터를 사용하였고 딥러닝 모델 평가 시 교차 평가로 UBFC, PURE, MMPD 모두 PURE로 학습된 가중치로 평가하였다. 따라서 세 데이터셋 모두 학습에 쓰이지 않은 영상으로 평가한다.

<표 1> 실험에 사용한 데이터셋의 구성

데이터셋	형식	해상도	fps	원본 개수	사용 개수
UBFC-rPPG	avi	640x480	30	42	27
PURE	PNG	640x480	30	59	59/12
MMPD	mat	240x320	30	132	132

2.1.2 방법별 설정

실험은 rPPG-Toolbox[7] 기반으로 WSL2의 RTX 4090(PyTorch 2.5.1, CUDA 12.1)에서 수행하였다. 얼굴 검출은 Haar Cascade[13]를 쓰고 검출 박스를 1.5배 넓혀 자르며, 모든 방법이 같은 설정을 공유한다. 알고리즘(GREEN, POS, CHROM)은 영상 전체를 한 번에 처리하며, 얼굴 영역을 72x72로 줄여 사용한다. POS와 CHROM은 약 1.6초 길이의 윈도우 슬라이딩하여 신호를 만든다. 같은 조건에서 세 방법은 같은 전처리 결과를 공유한다. 딥러닝(PhysNet, PhysFormer, PhysMamba)은 PURE로 사전학습된 가중치로 평가를 수행했다. 공통으로 입력 형식은 DiffNormalized, 배치 크기는 4이다. 딥러닝 모델은 입력 길이가 고정이라서 영상을 청크로 잘라 넣고, 청크별 예측을 이어 붙여 영상 단위의 신호를 만든다.

<표 2> 딥러닝 모델별 입력 및 주요 설정

항목	PhysNet	PhysFormer	PhysMamba
입력 크기	72x72	128x128	128x128
청크 길이	128	160	128
주요 파라미터	DROP_RATE 0.2, FRAME_NUM 128	PATCH 4, DIM 96, FF_DIM 144, HEADS 4, LAYERS 12, THETA 0.7, DROP 0.1	기본값
USE_LAST_EPOCH	TRUE	FALSE	FALSE

2.1.3 평가 지표

예측 신호에 대역통과 필터(0.6~3.3Hz)를 적용한 뒤 FFT로 심박수를 구하고, 정답 PPG에서 같은 방식으로 구한 심박수와 비교하였다. 평가 지표로는 MAE(bpm), RMSE(bpm), MAPE(%), Pearson, SNR(dB)를 사용하였다.

2.1.4 FPS 실험 설계

FPS는 30, 25, 20, 15, 10, 5로 총 6단계이며, 알고리즘과 딥러닝의 FPS 낮추는 방식은 다음과 같다. 알고리즘은 ffmpeg로 영상을 실제로 낮은 FPS로 다시 만든다. 영상 길이(초)는 그대로이고 프레임수만 줄여, 평가 시 샘플링 주파수(FS)도 해당 FPS로 바꾼다. UBFC는 정답 PPG를 새 프레임 수에 맞게 선형 보간으로 다시 만들었다. 딥러닝은 hold 방식으로 30fps 영상에서 일정 간격으로 대표 프레임을 고르고, 다음 대표 프레임이 나올 때까지 그 프레임을 반복한다. 프레임 수, FS=30, 정답은 그대로이다. 5fps에서는 알고리즘 전부가 실패한다. 평가 후 처리의 필터 상한(3.3Hz)이 나이퀴스트 주파수(2.5Hz)를 넘어 필터를 설계할 수 없기 때문이다. 알고리즘 중 CHROM은 10fps에서도 돌릴 수 없다. 윈도우가 16 프레임으로 줄어 필터가 요구하는 최소 신호 길이에 못 미치기 때문이다.

2.1.5 해상도 실험 설계

해상도는 UBFC, PURE 기준 6단계(640x480, 480x360, 320x240, 160x120, 80x60, 40x30)이며 fps는 30으로 고정한다. MMPD는 원본이 240x320으로 320x240 단계와 픽셀 수가 같아 픽셀 수를 기준으로 단계를 평가한다. 또한 원본보다 큰 두 단계는 키우지 않고 생략하여 4단계만 평가하였다. 축소 방식으로 OpenCV의 INTER_AREA를 모든 데이터셋에 동일하게 적용하였다. 딥러닝은 FPS 실험과 달리 hold 같은 근사 없이 실제로 줄인 영상을 해상

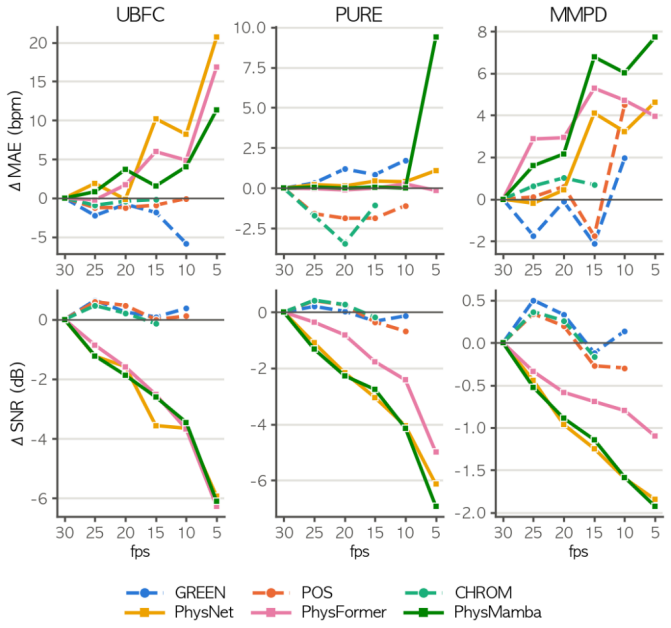
도마다 새로 전처리해서 평가한다.

2.2 실험 결과

2.2.1 FPS

알고리즘은 15fps까지 원본 수준을 유지하였다. UBFC에서 POS와 CHROM의 MAE는 15fps까지 1.4~2.6 범위였고 POS는 10fps(2.54)까지 동작하였다. 5fps에서는 모든 알고리즘이, 10fps에서는 CHROM이 구조적으로 평가되지 않았다. GREEN은 원본부터 성능이 낮았고 fps와 무관하였다. 딥러닝의 붕괴 지점은 데이터셋마다 달랐다. UBFC에서는 15fps에서 PhysNet이 1.76에서 11.95로, PhysFormer가 1.66에서 7.62로 증가하였고 PhysMamba는 3.12로 완만하였다. PURE에서는 10fps까지 0.15~0.81을 유지하다 5fps에서 PhysMamba만 9.52(Pearson 0.36)로 붕괴하였다. 딥러닝의 SNR은 fps가 낮아질수록 거의 단조 감소한 반면(PURE PhysNet 4.99 → −1.15) 알고리즘의 SNR은 거의 일정하여(UBFC POS −1.21 → −1.10), 딥러닝은 MAE가 유지되는 구간에서도 신호 품질이 먼저 저하되었다.

<그림 1> 프레임률 저하에 따른 원본(30fps) 대비 성능 변화량 (행: MAE, Pearson, SNR / 열: UBFC-rPPG, PURE, MMPD, 점선: 알고리즘 기반, 실선: 딥러닝 기반)



2.2.2 해상도

해상도가 낮아지면 얼굴 검출에 실패하는 영상이 생겨, 80×60 이하의 결과에는 해상도 자체의 영향과 검출 실패의 영향이 섞여 있다. 160×120 이상에서는 검출 실패가 거의 없었다(PURE 알고리즘 640×480과 160×120, MMPD 320×240과 160×120에서 각 1개). 80×60에서는 UBFC 27개 중 14개(52%), PURE 알고리즘 59세션 중 12세션(20%), MMPD 132개 중 7개(5%)가 실패하였고, PURE 딥러닝 12세션은 실패가 없었다. 40×30에서는 UBFC 27개와 PURE 알고리즘 59세션, PURE 딥러닝 12세션이 모두 실패하였고 MMPD는 94개(71%)가 실패하였다. UBFC에서는 160×120까지 영향이 거의 없었고(POS 2.20~3.47) 80×60에서 급증하였다(POS 9.52, 딥러닝6.28~11.78). 40×30에서는 딥러닝이 13.57~18.00, 알고리즘이 CHROM 9.20, POS 12.48로, 가장 낮은 해상도에서는 알고리즘이 덜 악화되었다. PURE 알고리즘은 160×120까지 유지되다 서서히 악화되었고(POS MAE 1.82 → 5.14, SNR 3.65 → −0.45), PURE 딥러닝은 40×30에서 12개 전부 검출에 실패했음에도 MAE 0.44~0.66을 유지하였으나 SNR은 크게 감소하였다(PhysNet 4.99 → 0.74). 이는 PURE에서 얼굴이 화면의 큰 부분을 차지하기 때문으로 추정된다. MMPD는 해상도의 영향이 작았다(PhysMamba 5.60 → 7.45).

3. 결 론

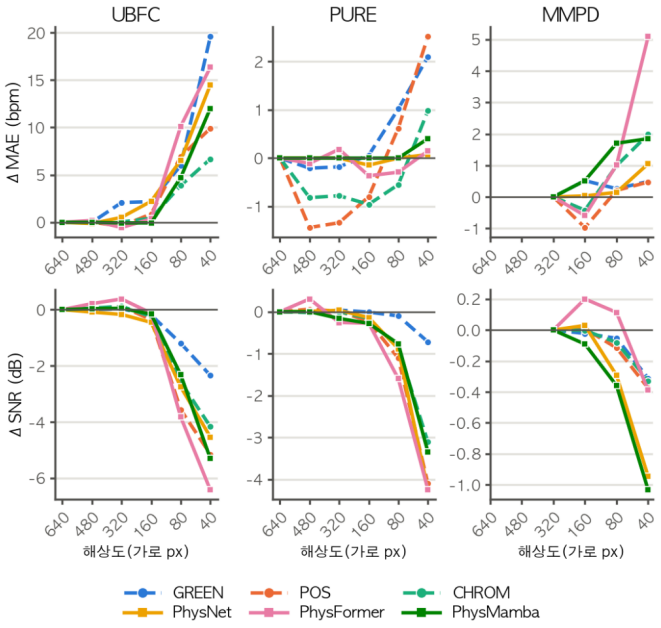
본 연구는 입력 영상의 프레임률과 해상도를 단계적으로 낮추며 알고리즘 기반 rPPG 방법 3종(GREEN, POS, CHROM)과 사전학습 딥러닝 모델 3종(PhysNet, PhysFormer, PhysMamba)의 심박수 추정 성능을 UBFC-rPPG, PURE, MMPD 데이터셋에서 비교하였다.

프레임률 실험에서 알고리즘 기반 방법은 15fps까지 원본 수준의 성능을 유지하였으나, 5fps에서는 후처리 필터의 상한이 나이퀴스트 주파수를 넘어 평가할 수 없었다. CHROM은 10fps에서도 윈도우 길이가 필터의 최소 신호 길이에 못 미쳐 평가할 수 없었다. 딥러닝 모델의 성능 붕괴 지점은 데이터셋에 따라 달랐다. UBFC에서는 15fps부터 오차가 크게 증가하였고, PURE에서는 10fps까지 성능을 유지하였다. 또한 딥러닝 모델은 MAE가 유지되는 구간에서도 SNR이 먼저 감소하였다. 따라서 저프레임률 환경에서는 MAE만으로 신호 품질을 판단하기 어렵다.

해상도 실험에서는 160×120까지 성능 변화가 거의 없었고, 80×60 이하에서 성능이 급격히 저하되었다. 다만 이 구간에서는 얼굴 검출 실패가 함께 발생하여 해상도 자체의 영향을 분리하지 못하였다.

이상의 결과는 저프레임률 및 저해상도 환경에서 rPPG 기반 심박수 추정을 적용할 수 있는 조건을 판단하는 기초 자료로 활용될 수 있다. 향후에는 프레임률 저하 방식을 알고리즘과 딥러닝에 동일하게 적용하고, 얼굴 검출의 영향을 배제한 조건에서 해상도의 영향을 분석할 예정이다.

<그림 2> 해상도 저하에 따른 원본 해상도 대비 성능 변화량 (행: MAE, Pearson, SNR / 열: UBFC-rPPG, PURE, MMPD, 점선: 알고리즘 기반, 실선: 딥러닝 기반)



[참 고 문 헌]

[1] W. Verkruysse, L. O. Svaasand, and J. S. Nelson, “Remote plethysmographic imaging using ambient light”, Opt. Express, vol. 16, no. 26, pp. 21434-21445, 2008.

[2] G. de Haan and V. Jeanne, “Robust pulse rate from chrominance-based rPPG”, IEEE Trans. Biomed. Eng., vol. 60, no. 10, pp. 2878-2886, 2013.

[3] W. Wang, A. C. den Brinker, S. Stuijk, and G. de Haan, “Algorithmic principles of remote PPG”, IEEE Trans. Biomed. Eng., vol. 64, no. 7, pp. 1479-1491, 2017.

[4] Z. Yu, X. Li, and G. Zhao, “Remote photoplethysmograph signal measurement from facial videos using spatio-temporal networks”, Proc. British Machine Vision Conf. (BMVC), 2019.

[5] Z. Yu, Y. Shen, J. Shi, H. Zhao, P. Torr, and G. Zhao, “PhysFormer: Facial video-based physiological measurement with temporal difference transformer”, Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), pp. 4176-4186, 2022.

[6] C. Luo, Y. Xie, and Z. Yu, “PhysMamba: Efficient remote physiological measurement with SlowFast temporal difference Mamba”, arXiv preprint arXiv:2409.12031, 2024.

[7] X. Liu et al., “rPPG-Toolbox: Deep remote PPG toolbox”, Advances in Neural Information Processing Systems (NeurIPS), Datasets and Benchmarks Track, 2023.

[8] E. B. Blackford and J. R. Estepp, “Effects of frame rate and image resolution on pulse rate measured using multiple camera imaging photoplethysmography”, Proc. SPIE 9417, Medical Imaging 2015, 94172D, 2015.

[9] D. J. McDuff, E. B. Blackford, and J. R. Estepp, “The impact of video compression on remote cardiac pulse measurement using imaging photoplethysmography”, Proc. IEEE Int. Conf. Automatic Face and Gesture Recognition (FG), 2017.

[10] S. Bobbia, R. Macwan, Y. Benezeth, A. Mansouri, and J. Dubois, “Unsupervised skin tissue segmentation for remote photoplethysmography”, Pattern Recognit. Lett., vol. 124, pp. 82-90, 2019.

[11] R. Stricker, S. Müller, and H.-M. Gross, “Non-contact video-based pulse rate measurement on a mobile service robot”, Proc. IEEE Int. Symp. Robot and Human Interactive Communication (RO-MAN), pp. 1056-1062, 2014.

[12] J. Tang et al., “MMPD: Multi-domain mobile video physiology dataset”, Proc. IEEE Eng. Med. Biol. Soc. Annu. Int. Conf. (EMBC), 2023.

[13] P. Viola and M. Jones, “Rapid object detection using a boosted cascade of simple features”, Proc. IEEE Comput. Soc. Conf. Comput. Vis. Pattern Recognit. (CVPR), 2001.