영상 해상도 및 프레임률 저하에 따른 rPPG 심박수 추정 성능의 붕괴 지점 분석

Breakdown Point Analysis of rPPG-Based Heart Rate Estimation Performance Under Degraded Video Resolution and Frame Rate

고은비[1] 정종진[2] 김승현[2*]

[1]대진대학교 일반대학원 방산AI융합학과 · [2]대진대학교 AI융합대학 교수

Eunbi Ko[1], Jongjin Jeong[2], Seunghyeon Kim[2*] | [1]Department of Defense AI Convergence, Graduate School, Daejin University [2]Professors, College of AI Convergence, Daejin University

1. 연구 배경 BACKGROUND

원격 광용적맥파(rPPG)는 얼굴 영상에서 미세한 피부색 변화를 읽어 심박수를 비접촉으로 추정하는 기술이다. **알고리즘 기반**(GREEN, POS, CHROM)과 **딥러닝 기반**(PhysNet, PhysFormer, PhysMamba) 방법이 제안되어 왔다.

알고리즘 기반에서 GREEN은 녹색 채널을 쓰고, CHROM은 색차 신호로 움직임의 영향을 줄이며, POS는 피부 반사 모델에 기반해 신호를 평면에 투영한다. 딥러닝 기반에서 PhysNet은 3차원 합성곱으로 영상의 시공간 특징에서 맥파를 직접 출력하고, PhysFormer는 시간 차분 트랜스포머로 장거리 시간 관계를, PhysMamba는 Mamba 구조로 긴 시계열을 효율적으로 처리한다.

그러나 이 방법들은 대부분 공개 데이터셋의 원본 프레임률과 해상도에서만 평가되었다. 실제 환경에서는 저전력 모드, 온디바이스·엣지 처리 등으로 프레임률과 해상도가 낮은 영상이 흔하다.

프레임률·해상도·영상 압축의 영향을 다룬 기존 연구는 딥러닝 이전의 알고리즘 기반 방법만을 대상으로 했다. 같은 저하에 두 계열이 어떻게 반응하는지, 어느 수준까지 쓸 수 있는지는 충분히 비교되지 않았다.

> **본 연구** 프레임률(30~5fps)과 해상도(640×480~40×30)를 단계적으로 낮추며, 알고리즘 3종과 딥러닝 3종의 심박수 추정 성능이 **붕괴 지점**을 3개 데이터셋에서 비교한다.

2. 설계 STUDY DESIGN

2.1 데이터 설정

표 1. 사용한 데이터셋의 구성 (세션 수, 세 데이터셋 모두 30fps)

데이터셋	해상도	원본	사용
UBFC-rPPG	640×480	42	27
PURE	640×480	59	59 (딥러닝 12)
MMPD	240×320	132	132

UBFC-rPPG는 파일 헤더가 선언한 크기와 실제 크기가 달라 정답 길이와 맞지 않는 15세션을 제외했다. PURE는 딥러닝 평가에 사전학습 구간과 겹치지 않도록 일부만 사용했고, 손상된 PNG 15개는 같은 세션의 이웃 프레임으로 대체했다. 딥러닝 모델은 세 데이터셋 모두 PURE로 사전학습된 가중치로 평가했다.

2.2 방법별 설정

얼굴은 Haar Cascade로 검출해 박스를 1.5배 넓혀 잘랐다. GREEN·POS·CHROM은 영상 전체를 한 번에 처리하며 얼굴 영역을 72×72로 줄이고, POS와 CHROM은 약 1.6초 윈도우를 슬라이딩한다. 딥러닝은 DiffNormalized 입력을 청크 단위로 예측해 이어 붙여 영상 단위 신호를 만든다.

표 2. 딥러닝 모델별 입력 설정 (청크 길이는 프레임 수)

딥러닝 모델	PhysNet	PhysFormer	PhysMamba
입력 크기	72×72	128×128	128×128
청크 길이	128	160	128

2.3 평가 지표

예측 신호에 0.6~3.3Hz 대역통과 필터를 적용하고 FFT로 심박수를 구해, 정답 PPG에서 같은 방식으로 구한 값과 비교한다. 지표는 **MAE(bpm), RMSE(bpm), MAPE(%), Pearson, SNR(dB)**이며, rPPG-Toolbox 기반으로 RTX 4090, PyTorch 2.5.1에서 수행했다.

2.4 프레임률·해상도 저하

프레임률 30 · 25 · 20 · 15 · 10 · 5fps. 알고리즘은 ffmpeg로 실제 낮은 fps 영상을 만들고 평가 샘플링 주파수도 맞췄다. 딥러닝은 일정 간격의 프레임을 골라 다음 프레임까지 반복하는 hold 방식으로 프레임 수를 유지했다.

해상도 640×480 · 480×360 · 320×240 · 160×120 · 80×60 · 40×30(30fps 고정)을 OpenCV INTER_AREA로 줄였다. 딥러닝도 hold 같은 근사 없이 실제로 줄인 영상을 전처리해 평가했다. MMPD는 원본이 240×320이라 4단계만 평가했다.

3. 실험 결과 RESULTS

3.1 FPS



그림 1. 프레임률 저하에 따른 방법별 성능 유지 여부 (본문 결과 요약)

5fps는 후처리 필터 상한(3.3Hz)이 나이퀴스트 주파수(2.5Hz)를 넘고, 10fps의 CHROM은 윈도우가 16프레임으로 줄어 필터 최소 신호 길이에 못 미쳐 평가할 수 없었다.

알고리즘은 15fps까지 원본 수준을 유지했다. UBFC에서 POS·CHROM의 MAE는 15fps까지 1.4~2.6 범위였고 POS는 10fps(2.54)까지 작았다. GREEN은 원본부터 성능이 낮고 fps와 무관했다.

딥러닝의 붕괴 지점은 데이터셋마다 달랐다. UBFC는 15fps에서 PhysNet이 1.76 → 11.95, PhysFormer가 1.66 → 7.62로 증가했고 PhysMamba는 3.12로 완만했다. PURE는 10fps까지 0.15~0.81을 유지하다 5fps에서 PhysMamba가 9.52(Pearson 0.36)로 붕괴했다.

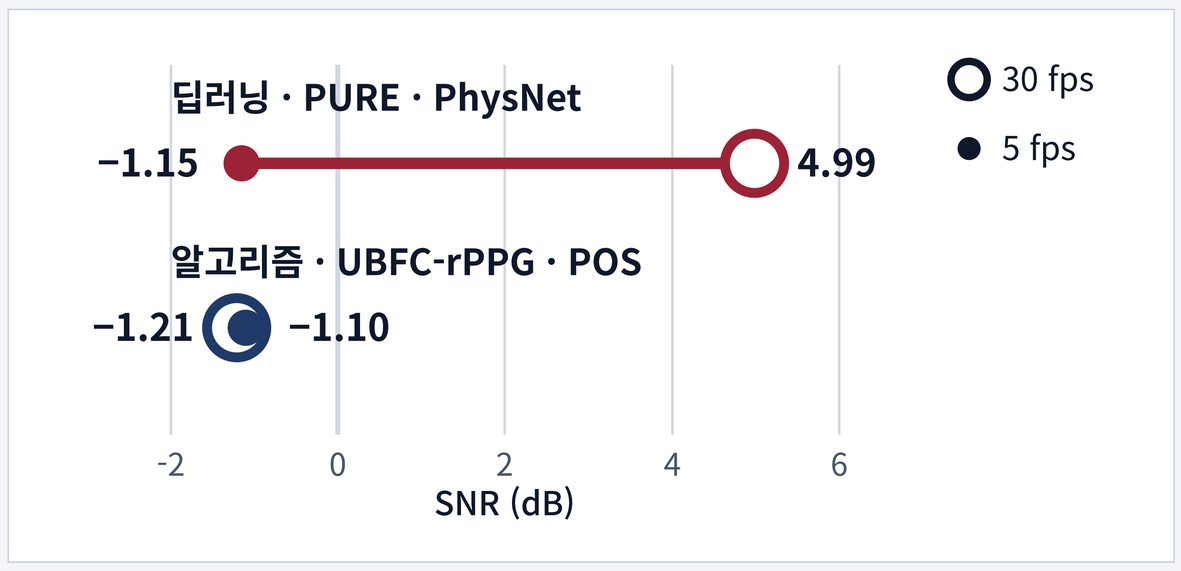


그림 2. 30fps → 5fps에서의 SNR 변화 (dB)

딥러닝의 SNR은 fps가 낮아질수록 거의 단조 감소했고, 알고리즘의 SNR은 거의 일정했다. 저프레임률 환경에서는 **MAE만으로 신호 품질을 판단하기 어렵다.**

3.2 해상도

해상도가 낮아지면 얼굴 검출에 실패하는 영상이 생겨, 80×60 이하의 결과에는 해상도 자체의 영향과 검출 실패의 영향이 섞인다. 160×120 이상에서는 검출 실패가 거의 없었다(해상도별 1세션 이하).

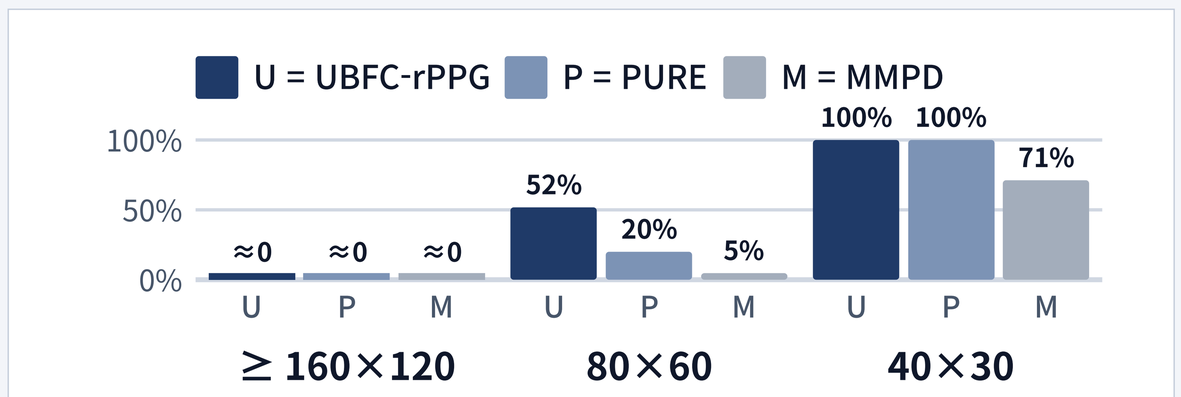


그림 3. 해상도별 얼굴 검출 실패 세션 비율 (U: UBFC-rPPG, P: PURE, M: MMPD). 80×60의 PURE는 알고리즘 기준(딥러닝 12세션은 실패 없음)

UBFC는 160×120까지 영향이 거의 없었고(POS MAE 2.20~3.47) 80×60에서 급증했다(POS 9.52, 딥러닝 6.28~11.78). 40×30에서는 딥러닝 13.57~18.00, CHROM 9.20, POS 12.48이었다.

PURE에서 알고리즘은 160×120까지 유지되다 서서히 저하되었다(POS MAE 1.82 → 5.14, SNR 3.65 → −0.45). 딥러닝은 40×30에서 검출이 전부 실패해도 MAE 0.44~0.66을 유지했지만 SNR은 크게 떨어졌다(PhysNet 4.99 → 0.74). PURE는 얼굴이 화면의 큰 부분을 차지하기 때문으로 추정된다. MMPD는 해상도의 영향이 작았다(PhysMamba 5.60 → 7.45).